

lab02_Antunes

Danilo Antunes

Tarefa

Lendo 100.000 observações por vez (se você acredita que seu computador não tem memória suficiente, utilize 10.000 observações por vez), determine o percentual de vôos por Cia. Aérea que apresentou atraso na chegada (`ARRIVAL_DELAY`) superior a 10 minutos. As companhias a serem utilizadas são: AA, DL, UA e US. A estatística de interesse deve ser calculada para cada um dos dias de 2015. Para a determinação deste percentual de atrasos, apenas verbos do pacote `dplyr` e comandos de importação do pacote `readr` podem ser utilizados. Os resultados para cada Cia. Aérea devem ser apresentados em um formato de calendário.

Observação: a atividade descrita no slide pede para ler apenas 100 registros por vez. Aqui, mudamos para 100 mil registros por vez, para que haja melhor aproveitamento do tempo em classe.

Instruções

1. Quais são as estatísticas suficientes para a determinação do percentual de vôos atrasados na chegada (`ARRIVAL_DELAY > 10`)?

Número total de vôos atrasados com `ARRIVAL_DELAY > 10` e número total de vôos.

2. Crie uma função chamada `getStats` que, para um conjunto de qualquer tamanho de dados provenientes de `flights.csv.zip`, execute as seguintes tarefas (usando apenas verbos do `dplyr`):
 - a. Filtre o conjunto de dados de forma que contenha apenas observações das seguintes Cias. Aéreas: AA, DL, UA e US;
 - b. Remova observações que tenham valores faltantes em campos de interesse;
 - c. Agrupe o conjunto de dados resultante de acordo com: dia, mês e cia. aérea;
 - d. Para cada grupo em b., determine as estatísticas suficientes apontadas no item 1. e os retorne como um objeto da classe `tibble`;
 - e. A função deve receber apenas dois argumentos:

- i. input: o conjunto de dados (referente ao lote em questão);
- ii. pos: argumento de posicionamento de ponteiro dentro da base de dados. Apesar de existir na função, este argumento não será empregado internamente. É importante observar que, sem a definição deste argumento, será impossível fazer a leitura por partes.

```
library(dplyr)
```

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

filter, lag

Os seguintes objetos são mascarados por 'package:base':

intersect, setdiff, setequal, union

```
library(readr)
library(knitr)

getStats <- function(input, pos) {
  input %>% filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
  filter(!is.na(YEAR),
         !is.na(MONTH),
         !is.na(DAY),
         !is.na(AIRLINE),
         !is.na(ARRIVAL_DELAY)) %>%
  group_by(YEAR, MONTH, DAY, AIRLINE) %>%
  summarise(n_total = n(),
            n_atrasados = sum(ARRIVAL_DELAY > 10),
            .groups = "drop")
}
```

3. Utilize alguma função readr::read_***_chunked para importar o arquivo flights.csv.zip.
 - a. Configure o tamanho do lote (chunk) para 100 mil registros;
 - b. Configure a função de callback para instanciar DataFrames aplicando a função getStats criada acima;
 - c. Configure o argumento col_types de forma que ele leia, diretamente do arquivo, apenas as colunas de interesse (veja nota de aula para identificar como realizar esta tarefa);

```
mycols = cols_only(YEAR = 'i',
                   MONTH = 'i',
                   DAY = 'i',
                   AIRLINE = 'c',
                   ARRIVAL_DELAY = 'd')

dados = read_csv_chunked('../dados/flights.csv.zip',
                        callback=DataFrameCallback$new(getStats),
                        chunk_size = 1e5, col_types=mycols)
```

4. Crie uma função chamada `computeStats` que:

- a. Combine as estatísticas suficientes para compor a métrica final de interesse (percentual de atraso por dia/mês/cia aérea);
- b. Retorne as informações em um tibble contendo apenas as seguintes colunas:
 - i. Cia: sigla da companhia aérea;
 - ii. Data: data, no formato AAAA-MM-DD (dica: utilize o comando `as.Date`);
 - iii. Perc: percentual de atraso para aquela cia. aérea e data, apresentado como um número real no intervalo [0,1].

```
computeStats = function(stats) {
  stats %>%
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%
    summarise(Perc = sum(n_atrasados) / sum(n_total),
              .groups = "drop") %>%
    mutate(Cia = AIRLINE,
           Data = as.Date(paste(YEAR, MONTH, DAY, sep = "-"))) %>%
    select(Cia, Data, Perc)
}

stats <- dados %>% computeStats()
head(stats) %>% kable()
```

Cia	Data	Perc
AA	2015-01-01	0.3727339
DL	2015-01-01	0.0847240
UA	2015-01-01	0.2892041
US	2015-01-01	0.1955253
AA	2015-01-02	0.4303714
DL	2015-01-02	0.1795666

5. Produza um mapa de calor em formato de calendário para cada Cia. Aérea.
- Instale e carregue os pacotes ggcal e ggplot2.
 - Defina uma paleta de cores em modo gradiente. Utilize o comando `scale_fill_gradient`. A cor inicial da paleta deve ser `#4575b4` e a cor final, `#d73027`. A paleta deve ser armazenada no objeto `pal`.
 - Crie uma função chamada `baseCalendario` que recebe 2 argumentos a seguir: `stats` (tibble com resultados calculados na questão 4) e `cia` (sigla da Cia. Aérea de interesse). A função deverá:
 - Criar um subconjunto de `stats` de forma a conter informações de atraso e data apenas da Cia. Aérea dada por `cia`.
 - Para o subconjunto acima, montar a base do calendário, utilizando `ggcal(x, y)`. Nesta notação, `x` representa as datas de interesse e `y`, os percentuais de atraso para as datas descritas em `x`.
 - Retornar para o usuário a base do calendário criada acima.
 - Executar a função `baseCalendario` para cada uma das Cias. Aéreas e armazenar os resultados, respectivamente, nas variáveis: `cAA`, `cDL`, `cUA` e `cUS`.
 - Para cada uma das Cias. Aéreas, apresente o mapa de calor respectivo utilizando a combinação de camadas do `ggplot2`. Lembre-se de adicionar um título utilizando o comando `ggtitle`. Por exemplo, `cXX + pal + ggtitle("Título")`.

```
library(ggcal)
library(ggplot2)

pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")

baseCalendario <- function(stats, cia) {
  dados_cia <- stats %>% filter(Cia == cia)


  calendario <- ggcal(dados_cia$Data, dados_cia$Perc)

  return(calendario)
}

cAA <- baseCalendario(stats, "AA")
cDL <- baseCalendario(stats, "DL")
cUA <- baseCalendario(stats, "UA")
cUS <- baseCalendario(stats, "US")


cAA + pal + ggtitle("Percentual de Atraso em Voos (AA)")
```

Percentual de Atraso em Voos (AA)




```
cDL + pal + ggtitle("Percentual de Atraso em Voos (DL)")
```

Percentual de Atraso em Voos (DL)




```
cUA + pal + ggtitle("Percentual de Atraso em Voos (UA)")
```

Percentual de Atraso em Voos (UA)



```
cUS + pal + ggtitle("Percentual de Atraso em Voos (US)")
```

Percentual de Atraso em Voos (US)



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-24 22:05:27 -03"
```